

# Rapport du projet

## Objectif du projet

L'objectif est de prédire le salaire en USD (*salary\_in\_usd*) à partir de variables liées au poste, au niveau d'expérience, à la localisation et aux caractéristiques de l'entreprise. Deux modèles de régression ont été comparés :

- **Régression linéaire**
- **Random Forest Regressor**

La performance des modèles a été évaluée principalement avec :

- le **R<sup>2</sup>** (coefficient de détermination)
- le **RMSE** (Root Mean Squared Error)

## Données et Prétraitement

Le jeu de données inclut des variables telles que : `work_year`, `experience_level`, `employment_type`, `job_title`, `salary_currency`, `employee_residence`, `remote_ratio`, `company_location`, `company_size`.

Les étapes de preprocessing ont consisté à :

- sélectionner les variables pertinentes
- gérer les valeurs manquantes
- encoder les variables catégorielles
- normaliser les données
- diviser le dataset (75% train / 25% test)

## Méthodologie

### 1. Régression Linéaire

- Test de **toutes les combinaisons possibles de 4 variables explicatives**
- Évaluation avec R<sup>2</sup> et RMSE

### 2. Random Forest

- Optimisation des hyperparamètres via **GridSearchCV** (`n_estimators`, `max_depth`, `min_samples_split`)
- Évaluation sur les mêmes critères (R<sup>2</sup>, RMSE)

## Résultats

### ❖ Régression Linéaire

- Performances très faibles
- $R^2$  souvent **négatif** en validation croisée
- RMSE élevé
  - => Le modèle n'explique pas correctement la variance du salaire
  - => Probable non-linéarité + multicollinéarité

### ❖ Random Forest

- Performances nettement supérieures
- $R^2$  moyen  $\approx$  **0,395** ( $\approx$  39,5% de variance expliquée)
- RMSE raisonnable
- Meilleure combinaison de variables :  
**experience\_level, job\_title, employee\_residence, remote\_ratio**

=> Random Forest capture mieux les relations complexes du dataset.

## Conclusion

La régression linéaire n'est pas adaptée aux données étudiées, probablement à cause de relations non linéaires et des contraintes imposées.

Le modèle **Random Forest** est le plus performant et serait retenu pour des prédictions futures.

Des améliorations potentielles incluent :

- feature engineering avancé
- optimisation d'hyperparamètres avec recherche bayésienne
- validation croisée renforcée
- tests de modèles plus complexes (Boosting, Neural Networks)

## Annexes

Sans optimisation d'hyperparamètres et avec un split 80/20 :

- Random Forest atteint environ **40% de variance expliquée**
- Meilleure combinaison :  
**experience\_level, job\_title, employee\_residence, company\_location**

Scripts fournis :

- pipeline.py : preprocessing
- main.py : entraînement + évaluation  
Résultats détaillés : Results.csv  
Tests additionnels : Annexe\_Results.csv